學號:R07922163 系級: 資工所二 姓名:徐浩翔

1. (0.5%) 請比較你實作的generative model、logistic regression 的準確率,何者較佳?

使用 logistic regression 做出來的效果比較好,下表為在 kaggle hw2 上的表現

| | private | public |
|---------------------|---------|---------|
| logistic regression | 0.84989 | 0.85552 |
| generative model | 0.84387 | 0.84373 |

其中不管是公開或是隱藏的測試資料皆為 logistic regression比較好

而我上傳了一份全部預測零的csv檔到kaggle hw2

在public 及private 上分別得到

0.76474與0.76282的預測正確率

表示資料大部分都屬於第零類(收入不超過美金50K)

因此generative model會受到先驗機率影響,得出來的預測值自然會比較小,所以表現比logistic regression差

2. (0.5%) 請實作特徵標準化(feature normalization)並討論其對於你的模型準確率的影響

在以logistic regression當作模型的狀況下

沒有標準化的資料在經過exponential時會overflow

而在kaggle hw2上的預測正確率只有0.78599

只比預測全部都是零的高0.02左右

因為若沒有經過normalization有些feature的數值範圍是10 00~2000有些是0~10

這樣在trainning時會給數值範圍比較小的有比較高的權重讓這個feature dominate預測結果但不應該這樣子所以會讓模型的準確率降很多

3. (1%) 請說明你實作的best model, 其訓練方式和準確率為何?

我使用的是 sklearn ensemble 中的gradient boosting classifier 其中跑得最的好的一些參數為:

Gradient Boosting Classifier(n_estimators = 1000, validation_fr action=0.01, n_iter_no_change=50)

將1%的資料做為validation set 防止model overfitting 超過50次迭代驗證集的loss沒下降就early stopping

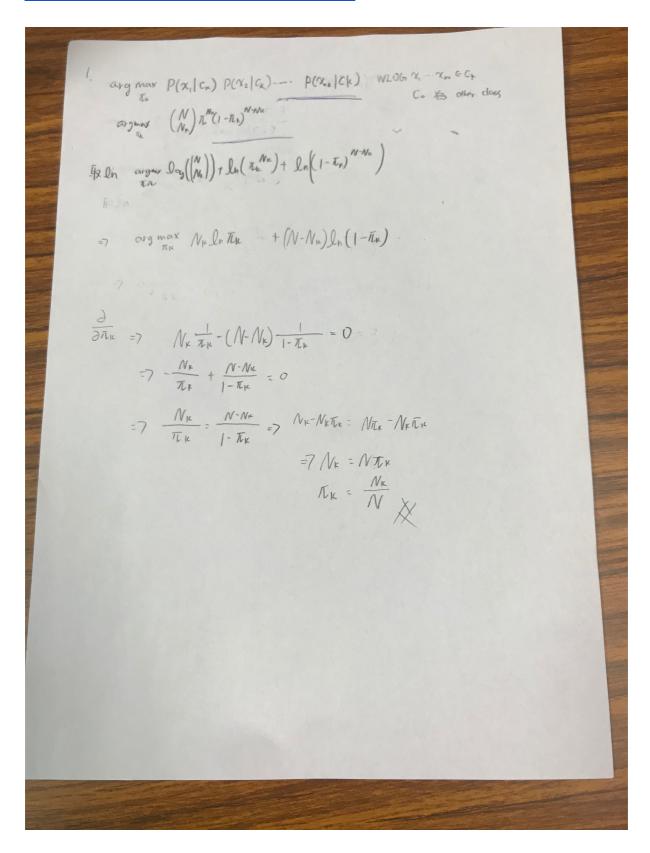
以下是使用 gradient boosting classifier在kaggle hw2上的結果

| private | publice | |
|----------------|---------------------|---------|
| 0.86500 | 0.87272 | |
| 0.87274 | 0.87936 | |
| 0.87274 | 0.88083 | |
| 0.87274 | 0.88132(publice最高的正 | .確率) |
| 0.87286 | 0.87960 | |
| 0.87372(ttpriv | ate第一高但未選擇) | 0.87936 |

另外我也有試過做五次gradient boosting 然後將每次結果做voting 三個以上的model預測1就將值設為一否則為0結果在public上會比單一model多預測錯一到兩筆但在private上得到了leaderboard第四名的成績其中public 更有第一高的正確率。

4. (3%) Refer to math problem

https://hackmd.io/0fDimgO7RaSCPpD_minSGQ?both



= OTI detC11 + OTE C12 -- OTIMEIN #P CIME cofactor matrix

(c) 為互扣掉i列i行所得的 m-1xm-1 矩阵 = Oxider Cai+ Ox2 Ciz -+ Oxi Caj+ --- Gam Cam

Aladetz) 1 Cis to題目左式為 decz Cij

classical adjains matrix adj(A) = CT (= [cn - cnm] (cm - cnm)

 $A^{-1} = \frac{1}{\det(A)} \operatorname{odj}(A)$ in $\operatorname{oj} Z^{-1} e_{i}^{-1} = \overline{Z}_{j,i}^{-1} \left(\operatorname{ER} A t \right)$

[(hx, E|x) = P(x, |Cx) P(x|Cx) -- P(xn, |Cx) # WLOG tix tax -- trix = 1 3-101) · N(x, M,Z) N(X, M,Z) - N(x, M, Z) $= \left(\frac{1}{(2\pi)^{\frac{1}{2}}} \frac{-(\chi_1 - M_2) Z'(\chi_1 - M_2)}{|Z|^{\frac{1}{2}} (2\pi)^{\frac{1}{2}}} \frac{(\chi_1 - M_2) Z'(\chi_1 - M_2)}{|Z|^{\frac{1}{2}} (2\pi)^{\frac{1}{2}} |Z|^{\frac{1}{2}}} \right)$ To In In(L(νε, Σ(x)) = (- D ln 2π+ 1 ln | Σ | - 1 (π- Ne) Σ (x- Ne)) + + (- 2 ln 2π+ (x- Ne)) = ((x- Ne) Σ (x- Ne)) 3 ln(1(1/2 × × ×)) = = = = = (- = (x,-Mx) - (x,-Mx) =)) + + = (-= (x,-Mx) =)) = - Z (x1-Mx) - Z (1/2-Mz) - - Z (1/2-Mx) = 0 .: Z' is covariance matthix is symmetric and nonsingular =) ラカーではガーウ 京(X)-MK)=0 ルK = 京な = 1 とtik (: tik Xi = 0 is i=nk)

(Nic 為題 Nic 存 敬称及改)

3-(6) similarly to (a) In(L(Ne. E | X) (- D lin 21 - 2 lin | Z | - 2 (x, - he) 2 (x, - he))+ th([]c 1) - th(c 2[]) + (- 2 ln 21 - 2 ln | 21 - 2 (xm ln) 2 (xm ln)) => ln(L(M,Z|X))=(-Dlnzx+=Dn|Z')-=(+r((x,-M,)(x,-M,)Z')) + (- 2 lo 2/2 + 1 2 lo 2) - 2 (tr ((xnx-Mx) (xnx-Mx) (\)))) (1/4, 2/2) = 1/2 = 1/2 (1/4, 1/4) (1/4, 1/4) $\left(-\frac{\ln |z|}{2z} - \left(z^{-1}\right)^T$ by problem and z is covariance matrix is symmetric) Share I so need to find L(M, Z|x') L(M,Z|x2) - L(M,Z|x*) and x',x2-x* AXEX XYECK ラ取り再っず WLOG X'為(X1-Xnx) $\left(\frac{h_1}{2}\sum_{i=1}^{N_1}(\chi_i-M_1)(\chi_i-M_1)\right) + - \left(\frac{n_k}{2}\sum_{i=1}^{N_1}(\chi_i-M_k)(\chi_i-M_k)\right) = 0$ = = \frac{\times Nk}{\times Nk} Sk \times